

Procesamiento Masivo de Datos

Alex Di Genova

August 18, 2026

Universidad de O'higgins

Bienvenida curso de PMD

Ejemplos donde se usa PMD

Planificación curso PMD

Bienvenida curso de PMD


Alex Di Genova

- 2003–2008 Ingeniero en Bioinformática.
- 2013-2017 Doctor en Sistemas Complejos.
- 2017-2021 Postdoctorado en algoritmos y cáncer (Francia).
- 2022-2023 Profesor Asistente UOH.
- 2023-Presente Profesor Asociado UOH.
 - Di Genoma Lab
 - Combinamos el desarrollo de nuevos algoritmos, análisis de genomas y tecnologías ómicas de última generación para estudiar sistemas biológicos complejos.


Ejemplos donde se usa PMD

Sequencing technologies


De novo genome assembly



Genome resequencing



Sequencer as counting devices



Shendure, Jay, et al. DNA sequencing at 40: past, present and future. *Nature* 550.7676 (2017):

Sequence ID: [CP030240.1](#) Length: 4582842 Number of Matches: 1

▼ Next Match ▲ Previous Match

Query	1	CACCAGCGTTAAACAGCAATAACAGCAGGACGATAATCAGCAGGTGATTACGTGCCAGTCC	60
Subject	168128	CACCAGCGTTAAACAGCAATAACAGCAGGACGATAATCAGCAGGTGATTACGTGCCAGTCC	168069

Sbict 168068 GCGCGTAATGGTCATAAATTCGCTAAGAAAAATGTTGAAGGGCGGCATCCCTGCCAGCGC 168009

Seq1 16800 CAGCGCAC GCCGCCAC CCGC CGCGGTAA G CATGATT TGGG TCCACAGAC 167949

Query 181 GACG⁺ GAGATCGCGCGT⁺GCCGTACT⁺T TATGCATGACAT⁺TGCCGGAACCGCAGAA CAGCAG 240

bp 167848 GACGTCAGATGGCGCTGGCTTCTCAGAGTAAATTCGGAACCGCAGAACAGCAG 167889

Query 241 CGCTTTTGCCAGACTGTGGTTTAAGATGTGCAGCAGCGCGGCAAAAATTCCCAGCGGCC 300

Human genome (30X) = \$1500

Query 301 G 301

Human genome (30X, BGI) = ~~_____~~ ~ \$5

Escherichia coli strain ER1709 chromosome, complete genome

Sequence ID: CP030240.1 Length: 4582842 Number of Matches: 1

▼ Next Match ▲ Previous Match

Query	94	CGCCACGGCT----ACACGTCGGTAATGCACGGTTCGCC-ACCAGACATATGGCCAGAGC	148
Shc1	129130	CGCCACGGCTGCACACACGTCGGTAATGCACGGTTCGCCACCGGAC--ATGGCCAGAGC	129187

Query 149 G--ATGGC-A-GCAGTCAAGGCT-A--C-ACGCGTC-GGCCAACGGTCAT-CCTGCCTGA 198

Sbict 129188 GTCATGGCGATACCTTTAACGGTCAGGCTACGCGTCAGCCCGGCGGTCACTCCCTGCCTGA 129247

Query 199 TGCAAAAAGCTGTCTGCC-TCACGAACAGATGTCTTTCAGCCCACGCGTTTGCACT-ACT 256

Sbjct 129248 TGCAAAAGCTGTCTGCCATCACGAACAGATG--TTTCAGCCCACGCGTTTGCGCTTGCT 129305

Query 257 GT-C-CTACT--TCTCTGAAG-CGGA---CATAAGCGTCTACCGGTGGAACGCTAAATGT 308

Sbjct 129306 GTCCGCAACTGCTCACCGAGCCCGGACCGCA-AAGCGTC-ACCGGTGGAACGCTAAATGT 129363

GenBank 309 TTTTACCGGTGCAGATTCTGGGTATCGATGCTCTGAAGTATGCTCGCTC-ACAATT 367

Sbjct 129364 TTTTACCGTTCAGATTCAAGG-TATCGACG-CTTGAA-AGA-GCGCGTCTGCAATT 129419

Query 368 CA-TTGGCATTAGGCCGCTCC CT-GCTCTC -CA TACGCAGCG-TCGCCAAGC-AGG 422

Sbjct 129420 CATTTTGCATATAGCCCTCCGCTTCTCTCGCCCACTAC-TGGCGATCGCC-AGCGGGG 129477

Human genome (30X) @ N1

Sbjct 129478 TCAT-AAACAAACTGTGCTGCGGT-AAATGCACCTGTAACGCCGGGAATTGTTTGC-GAA 129534

Sequencing technologies

Long


Read length = 15kb (Max 2Mb)

Query: 368 CG-TTGGCATTAGCCGCTGCGT-GCTCTCG-CTACTAG

Human genome (30X ONT) = \$3000




sbjct 129478 TCAT-AAACAAACTGTGCTGCGGT-AAATGCACCTGTAAACGCGGGAAATGTTTGC-GAA 129534
Human genome (30X PAC) = \$10000

Genome assembly



40 years of genome assembly

Genome assembly is complex



How do you get through?

How do we make “the” genome path?

Hybrid assembly: How can we combine short and long reads?

Sequencing technology

Genome

Identical repeats



Short reads (< 300 bp, base error < 0.1%)



Long reads (>10 kb, base error <15%)



Wengan Assembler

(1) Assemble short-reads



(2) Scaffold using long reads



(3) Refine repetitive regions (polishing)




The resulting assembly is both *contiguous and accurate*



Wengan: a new assembly paradigm

- **Full** hybrid assembler.
- Avoids entirely all-vs-all read comparisons (**fast**).
- A new assembly graph (*GoogleMaps*).
- 1.5 years of development.
- ~20k lines of code (C++, PERL)
- <https://github.com/adigenova/wengan>
- **Di Genova, A.** (2018). Fast-SG: an alignment-free algorithm for hybrid assembly. *GigaScience*, 7(5).
- **Di Genova, A.** (2021). Wengan: Efficient and high-quality hybrid de novo assembly of human genomes. *Nature Biotechnology*.



Wengan



ARTICLES

<https://doi.org/10.1038/s41587-020-00747-w>

nature
biotechnology



OPEN

Efficient hybrid de novo assembly of human genomes with WENGAN


Alex Di Genova^{1,2}✉, Elena Buena-Atienza^{3,4}, Stephan Ossowski^{3,4} and Marie-France Sagot^{1,2}✉

Generating accurate genome assemblies of large, repeat-rich human genomes has proved difficult using only long, error-prone reads, and most human genomes assembled from long reads add accurate short reads to polish the consensus sequence. Here we report an algorithm for hybrid assembly, WENGAN, that provides very high quality at low computational cost. We demonstrate de novo assembly of four human genomes using a combination of sequencing data generated on ONT PromethION, PacBio Sequel, Illumina and MGI technology. WENGAN implements efficient algorithms to improve assembly contiguity as well as consensus quality. The resulting genome assemblies have high contiguity (contig NG50: 17.24–80.64 Mb), few assembly errors (contig NGA50: 11.8–59.59 Mb), good consensus quality (QV: 27.84–42.88) and high gene completeness (BUSCO complete: 94.6–95.2%), while consuming low computational resources (CPU hours: 187–1,200). In particular, the WENGAN assembly of the haploid CHM13 sample achieved a contig NG50 of 80.64 Mb (NGA50: 59.59 Mb), which surpasses the contiguity of the current human reference genome (GRCh38 contig NG50: 57.88 Mb).

WENGAN is a Mapudungun word.

WENGAN means "Making the path".

Entrenando un LLM



Planificación curso PMD

- 4 Unidades (15 semanas)
 - Distribución y Paralelismo (4 semanas)
 - Modelamiento de Procesamiento Distribuido (5 semanas)
 - Modelos de Almacenamiento Escalable (3 semanas)
 - Bases de datos Distribuidas (3 semanas)

- Controles (75%, potenciales fechas de controles):
 - Control 1: Semana 5, 15/09
 - Control 2: Semana 10, 29/10
 - Control 3: Semana 14, 26/11
 - Control Recuperativo: Semana 15, 02/12

- Controles (75%, potenciales fechas de controles):
 - Control 1: Semana 5, 15/09
 - Control 2: Semana 10, 29/10
 - Control 3: Semana 14, 26/11
 - Control Recuperativo: Semana 15, 02/12
- Tareas (25%, potenciales fechas de entrega):
 - Tarea 1: Semana 5: Septiembre (15/09).
 - Tarea 2: Semana 13: Noviembre (17/11).

Condiciones y Políticas de Evaluación

- Se evaluará el aprendizaje del contenido presentado en las cátedras y en las ayudantías, mediante dos actividades complementarias (tareas, ejercicios) y tres controles de cátedra. Las ponderaciones de cada instancia de evaluación son las siguientes:
 - 1. Calificaciones en actividades complementarias 20%.
 - 2. Calificaciones en controles de cátedra 80%.
- La Nota Final del curso se calculará considerando las ponderaciones anteriores
- La aprobación de la asignatura está sujeta a las condiciones Nota Cátedra ≥ 4.0 y Nota de Actividades Complementarias ≥ 4.0 .

Condiciones y Políticas de Evaluación

- Estudiantes que se ausenten a un control tendrán la oportunidad de recuperarlo con el examen. La nota del examen reemplazará la nota más baja de los controles de la asignatura, solo si la nota del examen es superior.
- Un/a estudiante que cometa plagio obtendrá un 1,0 en la evaluación y el caso será informado a Escuela de Ingeniería.

Materiales

- Repositorio GitHub –
<https://github.com/adigenova/uohpmd>
 - Slides Clases (Martes [A312b] y Jueves [E405] : 10:00 - 11:20)
 - Código
- Ayudante : X Y (Jueves 16:00 - 17:20, E505)

Materiales

- Repositorio GitHub –
<https://github.com/adigenova/uohpmd>
 - Slides Clases (Martes [A312b] y Jueves [E405] : 10:00 - 11:20)
 - Código
- Ayudante : X Y (Jueves 16:00 - 17:20, E505)
- Ucampus –
<https://ucampus.uoh.cl/uoh/2026/2/COM4002/>
 - Comunicación (Consultas, noticias, evaluaciones)
 - Planificación

- Repositorio GitHub –
<https://github.com/adigenova/uohpmd>
 - Slides Clases (Martes [A312b] y Jueves [E405] : 10:00 - 11:20)
 - Código
- Ayudante : X Y (Jueves 16:00 - 17:20, E505)
- Ucampus –
<https://ucampus.uoh.cl/uoh/2026/2/COM4002/>
 - Comunicación (Consultas, noticias, evaluaciones)
 - Planificación
- Bibliografía
 - S. Tanenbaum, M. Van Steen. Distributed Systems: Principles and Paradigms (2nd Edition). Prentice Hall, 2006
 - P. J. Sadalage, M. Fowler. NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence. Addison-Wesley Professional, 2012

Resultados de Aprendizaje

- Conocer los principios fundamentales de diseño de sistemas distribuidos y paralelos (Linux)

Resultados de Aprendizaje

- Conocer los principios fundamentales de diseño de sistemas distribuidos y paralelos (Linux)
- Implementar comunicación entre procesos de una máquina (OpenMP, pthread)

Resultados de Aprendizaje

- Conocer los principios fundamentales de diseño de sistemas distribuidos y paralelos (Linux)
- Implementar comunicación entre procesos de una máquina (OpenMP, pthread)
- Implementar comunicación entre máquinas (MPI)

Resultados de Aprendizaje

- Conocer los principios fundamentales de diseño de sistemas distribuidos y paralelos (Linux)
- Implementar comunicación entre procesos de una máquina (OpenMP, pthread)
- Implementar comunicación entre máquinas (MPI)
- Utilizar Nextflow/Hadoop para distribuir tareas computacionales en un clúster.

Resultados de Aprendizaje

- Conocer los principios fundamentales de diseño de sistemas distribuidos y paralelos (Linux)
- Implementar comunicación entre procesos de una máquina (OpenMP, pthread)
- Implementar comunicación entre máquinas (MPI)
- Utilizar Nextflow/Hadoop para distribuir tareas computacionales en un clúster.
- Conocer la taxonomía de modelos de datos NoSQL, sus lenguajes de consulta y manipulación de datos con modelos NO-SQL.

Resultados de Aprendizaje

- Conocer los principios fundamentales de diseño de sistemas distribuidos y paralelos (Linux)
- Implementar comunicación entre procesos de una máquina (OpenMP, pthread)
- Implementar comunicación entre máquinas (MPI)
- Utilizar Nextflow/Hadoop para distribuir tareas computacionales en un clúster.
- Conocer la taxonomía de modelos de datos NoSQL, sus lenguajes de consulta y manipulación de datos con modelos NO-SQL.
- Construir y manipular una base de datos distribuida.

Consultas o comentarios?
Muchas Gracias.